


Pipeline ETL de données environnementales

**Automatisation de la qualité de l'air
et de la météo sur Google Cloud**



Problématique & Enjeux

Données dispersées

Les informations environnementales (qualité de l'air, météo) proviennent de sources hétérogènes et sont souvent fragmentées.

Analyse limitée

L'absence d'un historique structuré rend difficile l'analyse des tendances à long terme et la prise de décisions éclairées.

Fiabilité et automatisation

Un besoin crucial d'un mécanisme fiable et automatisé pour collecter, traiter et stocker ces données en continu.

Objectifs du Projet

1

1

Centraliser les données

Regrouper les données de qualité de l'air et météorologiques en une source unique et cohérente.

2

2

Historique fiable

Constituer un historique journalier complet et précis des données depuis le début de 2024.

3

3

Mise à jour automatisée

Implémenter un processus de mise à jour quotidienne entièrement automatique et sans intervention manuelle.

4

4

Données exploitables

Rendre les données accessibles et optimisées pour l'analyse, la visualisation et les applications futures.





19.15


Sources de Données

API Open-Meteo

Une source robuste et fiable pour la collecte des informations météorologiques et de qualité de l'air.

- **Qualité de l'air :** PM10, PM2.5, NO₂, O₃, Indice de Qualité de l'Air (AQI), etc.
- **Météorologiques :** Température, précipitations, vitesse et direction du vent, humidité, pression atmosphérique, etc.





Création de l'Histoire

La phase initiale du pipeline se concentre sur la constitution d'une base de données historique complète.



Extraction Rétrospective

Récupération des données depuis Janvier 2024 jusqu'à aujourd'hui.



Stockage Brut

Les données collectées sont d'abord stockées dans leur format original pour audit et rejeu.



Transformation

Nettoyage, enrichissement et agrégation des données brutes.



Transformation & Modélisation

La phase de transformation est cruciale pour rendre les données exploitables et prêtes pour l'analyse.

1

Agrégation journalière

Conversion des données horaires en moyennes ou cumuls journaliers pour simplifier l'analyse.

2


Alignement des données

Harmonisation des jeux de données de qualité de l'air et météorologiques par date et localisation.

3

Modèle final

Création d'un dataset unique avec une ligne par jour, optimisé pour les requêtes analytiques.



Pipeline Automatisé Quotidien

Un processus sans intervention, garantissant la fraîcheur et la complétude des données.

01

Collecte quotidienne

Récupération automatique des données de la veille via l'API Open-Meteo.

02

Traitement incrémental

Les nouvelles données sont transformées et agrégées, puis ajoutées à l'historique existant.

03

Orchestration serverless

L'intégralité du pipeline est gérée par des services cloud, minimisant l'overhead opérationnel.


Architecture Cloud sur Google Cloud

Cloud Storage

Stockage sécurisé et scalable pour les données brutes (raw) et nettoyées (clean).

BigQuery

Entrepôt de données analytique pour le stockage final des données modélisées, optimisé pour les requêtes.



Cloud Run Jobs

Exécution des tâches d'extraction et de transformation (batch) de manière serverless.

Cloud Scheduler

Planification des exécutions quotidiennes du pipeline, assurant l'automatisation.



Résultats & Valeur Ajoutée

1

Historique Complet

Accès à un historique détaillé des données environnementales depuis janvier 2024.

2

Données Prêtes à l'Emploi

Des données nettoyées, agrégées et modélisées, parfaites pour l'analyse et la visualisation.

3

Architecture Robuste

Un pipeline serverless, scalable, et facile à maintenir, garantissant la fiabilité.

4

Décisions Éclairées

Supporte la prise de décisions basées sur des données pour la gestion environnementale.

Conclusion & Perspectives

Pipeline Opérationnel

Un pipeline ETL robuste et entièrement automatisé est désormais en production.

Extensions Possibles

Ajout de nouvelles villes, intégration avec des dashboards, développement de modèles prédictifs.

Impact Durable

Une base solide pour des analyses environnementales approfondies et à long terme.

